UNIVERSIDADE FEDERAL RURAL DE PERNAMBUCO

PRÓ-REITORIA DE PESQUISA E PÓS-GRADUAÇÃO
COORDENADORIA DE PROGRAMAS ESPECIAIS

Relatório de plano de trabalho
PIC/CNPq/UFRPE

Aluno: Airton Martins Neris
Curso: Bacharelado em Sistemas de Informação
Programa: ( )PIBIC (X)PIC ( ) PIBIC-EM
Orientador: Glauco Estácio Gonçalves
Departamento/Área: Departamento de Estatística e Informática / Sistemas Computacionais
Relatório: ()Parcial (X) Final
Título do Projeto: Avaliação de plataformas de armazenamento em nuvem para dados de sensores

1 Resumo

A coleta manual de dados de parâmetros ambientais acarreta problemas como insuficiência e descontinuidade dos dados e medidas sem precisão. Contudo, a tecnologia da informação pode ser utilizada para mitigar esse tipo de problema por meio da telemetria. Técnicas modernas como o *Sensing as a Service*, um serviço que adquire, armazena e processa dados de múltiplos sensores espalhados por uma região entregando-os ao usuário final, podem ser utilizadas neste sentido. Sistemas como este geram um grande volume de dados e necessitam de serviços de armazenamento que garantam consistência, disponibilidade e tolerância a falhas.

Neste plano pesquisa, investigamos e avaliamos tecnologias para armazenamento de dados oriundos de sensores de estações meteorológicas no contexto de um sistema *Sensing as a Service*. A metodologia deste trabalho consiste no estudo dos principais requisitos para armazenamento de dados de sensores meteorológicas e na avaliação de tecnologias e métodos de armazenamento mais adequados por meio de testes quantitativos. Este relatório apresenta avaliações das plataformas em cenários com diferentes números de estações e clientes, possibilitando uma avaliação do comportamento de diferentes sistemas de armazenamento de dados no contexto proposto.

Como diferenciais destes experimentos frente a outros da literatura podem-se destacar a avaliação dos principais modelos de bancos de dados citados na literatura (relacional, NoSQL e NewSQL); a organização dos dados segundo modelos mais próximos daqueles encontrados em um sistema de sensoriamento real; e a realização de consultas complexas tais como as encontradas nestes sistemas. Os resultados mostraram que o banco NoSQL (MongoDB) alcança tempos de inserção e consulta inferiores aos demais bancos avaliados em todos os cenários testados. Além disso, foi possível constatar que a forma como os dados estão organizados impacta os resultados obtidos em consultas complexas.

Além dos resultados obtidos na avaliação dos bancos de dados destacam-se como contribuições deste plano de trabalho: a) o levantamento do estado da arte com trabalhos específicos sobre bancos de dados em sistemas S²aaS; e b) Construção de uma ferramenta parametrizada para execução automática dos experimentos, a qual será empregada em futuros experimentos dentro do projeto de pesquisa.

2 Introdução

A coleta de parâmetros ambientais é essencial para que pesquisadores possam monitorar, analisar e compreender processos e fenômenos naturais [1][2]. A Coleta manual destes parâmetros exige demasiado esforço humano visando a correta sistematização dos dados. Isto acarreta problemas, tais como insuficiência e descontinuidade dos dados e medidas imprecisas, que comprometem o resultado final do trabalho. A instrumentação do ambiente através de sensores e dispositivos de armazenamento dos dados coletados soluciona muitos desses problemas. No entanto, ainda não é comum o uso de um serviço flexível que colete estes dados e os disponibilize para os usuários finais de maneira eficiente.

Uma das formas de criar estes mecanismos para coleta e monitoramento é o emprego de técnicas presentes em sistemas de Internet das Coisas (IoT - *Internet of Things*) aliados à serviços em nuvem. Chamado de *Sensing as a Service* (Sensoriamento como um serviço -S²aaS) [3], este tipo de serviço é composto por diversas estações de coleta com múltiplos sensores que enviam periodicamente os dados coletados em seus sensores, por meio de módulos de transmissão sem-fio, a serviços de armazenamento, processamento e visualização centralizados na Nuvem.

O S²aaS difere dos mecanismos tradicionais de telemetria por Internet utilizados há anos em soluções de sensoriamento remoto [2], por conta da possibilidade de compartilhar a infraestrutura de estações de coleta entre diversos usuários que dinamicamente reconfiguram a infraestrutura para atender seus interesses de coleta.

Assim, além de permitir a coleta eficiente dos dados e a possibilidade do monitoramento da saúde das estações de coleta, o S²aaS permite compartilhar todo o conjunto de sensores instalados entre múltiplos usuários que estejam interessados em observar fenômenos diferentes a partir dos dados dos mesmos sensores.

Em um sistema S²aaS, o volume de dados gerado e o número de clientes acessando estes dados cresce rapidamente [4]. Esta característica exige que os dados sejam armazenados em um sistema que possa garantir consistência, disponibilidade e tolerância à falhas. Contudo, como afirma o teorema CAP [5], só se pode obter no máximo duas destas três propriedades. Por isso, sistemas de armazenamento de dados fazem escolhas diferentes, priorizando duas das propriedades em detrimento de outra, de acordo com os requisitos que pretendem atender.

No armazenamento de dados, de modo geral, podemos destacar três classes de bancos de dados utilizadas: a classe relacional (que chamaremos SQL), a classe NoSQL e a classe NewSQL. Os bancos de dados relacionais usam estruturas de tabelas fixas e tem capacidade de selecionar dados a partir dessas tabelas com uma linguagem de consulta estruturada[6]. Um banco de dados SQL normalmente é escalável verticalmente, isto é, é executado em um único servidor cujo hardware é atualizado para oferecer maior desempenho.

A classe NoSQL (*Not only SQL*), como apontado em [7], incluem um grande número de bancos de dados que não são baseados no modelo relacional, incluindo algumas soluções projetadas para aplicações muito específicas, como armazenamento de grafos, em colunas, chave-valor e documentos. Embora esta classe seja bastante abrangente, de forma geral atribui-se aos bancos desta classe as seguintes características: modelos de dados não-relacional simples e flexível, capacidade de escalar horizontalmente, alta disponibilidade e tolerância a falhas.

Em [7], o NewSQL é citado como um termo usado para classificar um conjunto de soluções visando trazer ao modelo relacional os benefícios da escalabilidade horizontal e tolerância a falhas fornecidos por soluções NoSQL. A maioria desses bancos de dados suportam o modelo relacional e usam o SQL como linguagem e, de um modo geral, atendem a muitos dos requisitos de gerenciamento de dados em ambientes de nuvem e também possuem Os benefícios do padrão SQL.

Esta multiplicidade de classes e tipos de bancos de dados fornece motivação para investigar quais destes seriam mais adequados aos sistemas de sensoriamento como serviço.

3 Objetivos

3.1 Geral

Investigar e avaliar métodos e tecnologias para armazenamento de dados de sensores em um sistema S²aaS. Pretende-se avaliar o desempenho e escalabilidade de bancos de dados NoSQL, SQL e NewSQL na execução de tarefas de escrita e recuperação de dados de sensores. Além disso, pretende-se avaliar diferentes métodos de armazenamento dos dados coletados.

3.2 Específicos

De forma específica, pretende-se:

- Levantar os requisitos de armazenamento de um sistema S²aaS.
- Analisar métodos e tecnologias para armazenamento em nuvem.
- Desenvolver ferramentas para testes de envio/consumo dados sintéticos de sensores.

- Comparar, por meio de medições, as principais tecnologias para armazenamento em nuvem.

4 Metodologia

Estes primeiros seis meses foram dedicados ao levantamento do estado da arte acerca do emprego das tecnologias de armazenamento de dados de sensores em um sistema S²aaS que atende as necessidades do projeto Aplicação de Teoria do Controle Supervisório em Sistema IoT Multi-usuário para Telemetria de Parâmetros Ambientais. Na fase do levantamento, buscou-se artigos nas principais conferências e periódicos envolvendo a análise de bancos de dados para IoT. Todos os artigos lidos foram catalogados e resumidos.

A partir do estudo destes requisitos, foram investigadas as diferentes tecnologias para armazenamento dos dados em nuvem bancos de dados SQL, NoSQL e NewSQL. Também foram investigados os métodos mais adequados para armazenamento de dados de sensores e aspectos da organização dos dados. As tecnologias e os métodos de armazenamento mais adequados foram escolhidos para realização de testes quantitativos. Este teste será feito por meio da escrita e leitura de dados reais a partir da emulação de sensores geograficamente espalhados e da recuperação de dados a partir de clientes também emulados.

As atividades deste plano estão sendo realizadas na UFRPE, com carga horária de 20h semanais divididas em cinco dias. As etapas foram apresentadas no início do trabalho, contemplando uma programação das atividades a serem realizadas. Dentro da carga horária diária, o aluno desenvolveu diversas tarefas associadas às atividades de leitura de artigos e escrita de relatório, o levantamento de dados acerca do problema e a pesquisa de soluções existentes. Assim, o aluno teve a oportunidade de vivenciar a prática discutida pela teoria. Todo este trabalho se desenvolveu sob a supervisão direta do orientador.

5 Resultados e Discussão

5.1 Estado da Arte

Como dito na seção anterior, os primeiros seis meses de execução do plano tiveram foco especifico em três itens: a) no estudo mais apurado dos requisitos de armazenamento de ambientes de sensoriamento como serviço; b) levantamento do estado da arte; c) na definição de objetivos, parâmetros e métricas dos experimentos de desempenho dos bancos de dados.

Na fase do levantamento, foram observados vários artigos que analisam diferentes tipos de bancos de dados, com foco em dados de sensores. Dentre os artigos lidos, pode-se destacar o trabalho de Van der Veen et al.[6], que compara o desempenho relativo de 3 diferentes tipos de banco de dados (PostgreSQL,Cassandra e MongoDB) no armazenamento dos dados de sensores. Cada sensor envia dados que são minimamente identificados por um id do sensor que envia, o momento (*timestamp*) em que a medida foi feita e pelo dado da medida. Foram feitos experimentos utilizando 4 operações: escrita em lote, leitura em lote, escritas individuais e leituras individuais. Estes foram realizados em cenários com um cliente e múltiplos clientes. Os autores argumentam que escritas individuais e leitura em lote são as mais adequadas para sistemas de sensoriamento como serviço, contudo, dos três bancos de dados testados, não existe um único que tenha o mesmo desempenho em ambas as operações.

Em [8], os autores abordam a adequação de diferentes tipos de bancos de dados em nuvem para a Internet das coisas. Especificamente, este trabalho compara o desempenho de um banco SQL (MySQL) e três bancos de dados NoSQL (MongoDB, CouchDB e Redis) em um ambiente de nuvem usando diferentes tipos de dados da Internet das coisas. Em outras palavras os autores avaliaram não só o armazenamento de dados de sensores escalares - como os empregados em medições meteorológicas simples (ex.: temperatura,

pressão, umidade etc)-, como também dados de sensores multimídia (ex: câmeras termais, radar etc). Focando apenas nos resultados dos experimentos com sensores escalares (presentes no cenário que estamos investigando nesta pesquisa), os autores concluíram que o MongoDB desponta como uma opção equilibrada, oferecendo o melhor desempenho em operações de escrita dentre os bancos estudados, e um desempenho pouco abaixo dos melhores (Redis e MySQL) na leitura. Os autores destacam ainda que o CouchDB ofereceu o pior desempenho em todas as métricas observadas.

Em [9], é feita uma análise em relação à performance de alguns Bancos NoSQL e SQL com foco em armazenamento de chave - valor. É comparada a leitura, escrita e exclusão com operações chave-valor e uma operação adicional iterando através de todas as chaves. Os bancos de dados utilizados foram MongoDB, RavenDB, CouchDB, Cassandra, Hypertable, Couchbase, como representantes NoSQL, e o Microsoft SQL Server Express. Os autores concluem que, a despeito de serem otimizados para consultas chave-valor, apenas em parte dos bancos de dados NoSQL testados superam o banco SQL escolhido. O Couchbase e MongoDB são apontados pelos autores como uma boa escolha por apresentarem um melhor desempenho em todas as operações.

Fatima e Wasnik [10] realizam uma análise qualitativa das classes de bancos de dados SQL, NoSQL e NewSQL por meio das características de bancos de dados de código aberto representativos de cada classe: MySQL, representando a classe dos relacionais; MongoDB e Cassandra, que são NoSQL; e VoltDB, como o representante do NewSQL. Embora o trabalho tenha feito apenas uma análise inicial, os resultados apontam que bancos de dados da classe NewSQL se apresentam como opções interessantes para sistemas de sensoriamento como serviço, pois aliam consistência com uma maior capacidade de replicação.

As análises qualitativas realizadas por Grolinger et al.[7] oferecem uma visão mais profunda das similaridades e diferenças entre as classes NoSQL e NewSQL. Englobando 19 bancos de dados, os autores apresentam comparações numa série de dimensões como: modelos de dados suportados, recursos de consulta, capacidade de replicação, atributos de segurança e outros. Além de fazerem a comparação, os autores ainda discutem os melhores bancos para diversos cenários de uso. No caso de sensoriamento como serviço, os autores indicam bancos de dados orientados à documentos como o MongoDB devido a capacidade de ter um esquema adaptável, o que facilitaria a mudança do banco para atender a entrada de novos tipos de sensores.

A Tabela 1 sumariza os trabalhos relacionados. Como se pode depreender da tabela, dentre os trabalhos que realizaram avaliações quantitativas, todos utilizaram bases de dados sintéticas, o que significa uma organização de dados mais simples e distante da realidade. Outra observação importante é que não há trabalhos que comparem o desempenho de bancos de dados NewSQL no cenário de dados de sensores. De modo a cobrir estas lacunas, estruturamos um experimento que avalie os melhores bancos das três classes de bancos de dados, conforme discutimos na Seção 5.2.

Trabalhos	Bancos avaliados	Tipo de avaliação	Operações	Tipo de base
[8]	MySQL(SQL), MongoDB(NoSQL), CouchDB(NoSQL), Redis(NoSQL)	Quantitativa	Inserção Consulta	Sintética
[6]	PostgreSQL(SQL), Cassandra (NoSQL), MongoDB (NoSQL)	Quantitativa	Inserção Consulta	Sintética
[9]	MongoDB (NoSQL), RavenDB (NoSQL), CouchDB (NoSQL), Cassandra (NoSQL), Hypertable (NoSQL), Couchbase (NoSQL), Microsoft SQL Server (SQL)	Quantitativa	Criação do banco, Inserção, Consulta, Exclusão	Sintética
[10]	MySQL (SQL), MongoDB (NoSQL), Cassandra (NoSQL), VoltDB (NewSQL)	Qualitativa	NA	NA
[7]	Redis (NoSQL), Memcached (NoSQL), BerkeleyDB (NoSQL), Voldemort (NoSQL), Riak (NoSQL), Cassandra (NoSQL), HBase (NoSQL), DynamoDB (NoSQL), Amazon SimpleDB (NoSQL), MongoDB (NoSQL), CouchDB (NoSQL), Couchbase server (NoSQL), Neo4J (NoSQL), Hyper GraphDb (NoSQL), Allegro graph (NoSQL), VoltDB (NewSQL), Spanner (NewSQL), Clustrix (NewSQL), NuoDB (NewSQL),	Qualitativa	NA	NA

Tabela 1: Comparação dos trabalhos relacionados

5.2 Definições dos experimentos

O experimento descrito nesta subseção teve como objetivo investigar os banco de dados mais adequados ao armazenamento de dados de sensores em ambientes de sensoriamento como serviço. Aqui são apresentados os parâmetros dos experimentos que foram executados nos ultimos meses do plano de trabalho.

Os trabalhos relacionados tem como característica comum o uso de estruturas e bases de dados sintéticas. Contudo, neste trabalho foram utilizados dados provenientes de oito estações meteorológicas do portal de dados abertos da Prefeitura do Rio de Janeiro[1]. Por conta disto e diferentemente dos experimentos em [6] que utilizaram uma organização mínima e [8] que propôs o desenvolvimento de duas estruturas de tabelas diferentes, estes experimentos utilizam uma única estrutura de tabelas que procuram se aproximar dos modelos de dados utilizados em sistemas de estações meteorológicas reais.

Um sistema de sensoriamento como serviço trabalhando com estações meteorológicas reais contém estações nas quais estão ligados diversos sensores de diferentes tipos. Nos dados utilizados neste trabalho, por exemplo, cada estação possui sete sensores associados a ela. A estação captura periodicamente os dados dos sensores, armazena localmente as amostras e, conforme um intervalo de tempo previamente configurado, os envia ao sistema de aquisição de dados na nuvem. A estrutura dos dados desenvolvida procura capturar a natureza destes dispositivos, conforme mostra o diagrama Entidade-Relacionamento na Figura 1.

O modelo captura a relação entre duas tabelas, nomeadas como Sensor e Histórico. A tabela Sensor irá conter as seguintes informações: **Id**, referente a identificação única; **Tipo**, referente a que tipo de medição é feita pelo sensor; e **Estação**, que relaciona o sensor à estação de coleta em que ele está instalado. Este último atributo permite o relacionamento futuro da tabela Sensor com uma Tabela Estação, mas não será utilizada nesta avaliação porque o foco será em consultas mais simples. Já a tabela Histórico contém os campos: **id_sensor**, referente a chave estrangeira da tabela Sensor; **Timestamp**, referente ao tempo no qual a medição foi inserida; Valor: referente ao valor que foi medido.

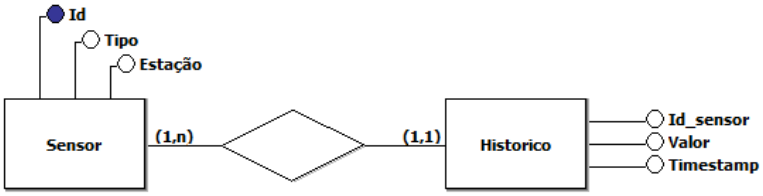

Figura 1: Modelo Entidade-Relacionamento do Banco de Dados a ser experimentado.

Os testes foram divididos em dois experimentos: inserção e consulta. A Tabela 2 mostra os parâmetros comuns aos dois experimentos. O principal fator variado nos dois experimentos foram os banco de dados que são mostrados na Tabela 3. Como métrica foi computado a latência média das operações em ambos os experimentos.

Parâmetro	Valor
Computador Cliente	Intel Core i7-3770 CPU @ 3.40 GHz x 2, 4 GB RAM, Ubuntu server 16.04 64bit
Computador para BD	Intel Core i7-3770 CPU @ 3.40 GHz x 1, 4 GB RAM, Ubuntu server 16.04 64bit
Comunicação	Switch GigaBit Ethernet

Tabela 2: Parâmetros comuns aos dois experimentos

Fator	Níveis
Bancos de dados	PostgreSQL 9.6.02, MongoDB 3.4.2 e VoltDB 6.0.1

Tabela 3: Fatores comuns aos dois experimentos

[1] http://data.rio/

Foram utilizados os bancos de dados PostgreSQL, MongoDB e VoltDB. O PostgreSQL é um SGBD relacional e *open source*, cuja inclusão nesta avaliação se dá por ser utilizado como uma referência nos trabalhos estudados ([8] e [6]) e apresentar um bom desempenho em operações de leitura. Já o MongoDB é um banco de dados NoSQL *open source* de alta performance, orientado a documentos. Também foi utilizado na maioria dos experimentos e apresentou bom desempenho em operações de escrita. Por fim, empregamos o VoltDB como representante dos banco de dados NewSQL, que permitirá averiguar o comportamento desta categoria no cenário de dados de sensores.

O experimento de inserção compreende a escrita sequencial de registros no banco de dados. A Tabela 4 mostra os dois fatores utilizados: número de estações concorrentes e a aplicação. O primeiro fator permite observar o comportamento do banco de dados com o aumento do número de estações de coleta de dados. Pretende-se variar de 2 a 8 estações (número total de estações nos dados utilizados) enviando dados simultaneamente.

Já o segundo fator permite verificar como os bancos se comportam frente a dois tipos diferentes de envio de dados. O primeiro tipo procura simular a inserção dos dados feita em tempo real pelas estações. Por tempo real, queremos definir os casos em que cada estação manda seus dados em intervalos breves - 10 minutos, no caso dos dados empregados - de modo a manter uma aplicação atualizada com dados mais recentes. O segundo permite observar o caso de aplicações que toleram o envio de dados coletados em um lote único, compreendendo o envio diário de dados. Assim, os dados coletados a cada 10 minutos seriam acumulados durante o dia e enviados em conjunto. Note que a escolha de uma outra forma não impacta no número de inserções feitas - já que a mesma quantidade de registros será inserida em cada caso-, mas impacta no volume e na forma como as operações são feitas no banco de dados no momento da inserção. Com isso observamos como o banco se comporta frente a estas diferentes formas de inserção.

Fator	**Níveis**
Estações concorrentes	2, 3, 4, 5, 6, 7 e 8
Aplicação	Tempo real e Em lote

Tabela 4: Fatores do experimento de inserção

Conforme observado por [6], leituras em lote são comuns em ambientes de sensoriamento como serviço. Contudo, deve-se especificar que o desempenho desta consulta depende também da forma como os dados estão organizados no banco e do tipo de informação que se deseja levantar. Em nossa avaliação, o experimento de consulta foi realizado por meio de operações de consultas sequenciais à dados previamente carregados no banco de dados. A Tabela 5 mostra os fatores envolvidos no experimento de consulta.

Fator	**Níveis**
Tipo da consulta	Por estação e Por tipo de sensor
Período da consulta	Tempo real e Histórico
Consultas concorrentes	1, 5 e 10

Tabela 5: Fatores do experimento de inserção

O experimento avaliou consultas que variam em duas dimensões: quanto ao tipo e quanto ao período. No tipo escolhemos consultas típicas em sistemas de sensoriamento como serviço: consultas por estação, que retorna as medidas de todos os sensores de uma determinada estação, e consultas por tipo sensor, que retorna as medidas de todos os sensores de um tipo considerando todas as 8 estações do sistema. As duas consultas foram feitas para dois períodos diferentes denominados tempo real, para aquisição de dados recentes dos últimos 10 minutos, e histórico, para retorno de dados de um mês.Cada estação concorrente efetuou 35 consultas de dados escolhidos aleatoriamente. O cruzamento destas duas dimensões permitiram observar o comportamento dos bancos frente a situações com consultas simples e complexas e com volumes de dados diferentes. Além destas dimensões, o experimento de consulta avaliou o impacto de múltiplas consultas

simultâneas variando entre: 1, 5 e 10 clientes.

Para a execução dos experimentos foi desenvolvida uma ferramenta parametrizada em linguagem Java para a execução de operações de inserção e consulta. A ferramenta foi construída de forma a executar experimentos com diferentes parâmetros como tipo do experimento (inserção ou consulta), banco candidato, número de repetições, conjunto de dados a serem utilizados etc. Com base nos parâmetros selecionados por seu operador, a ferramenta faz o direcionamento para cada experimento, carregando as bibliotecas de programação e empregando as funções necessárias para execução. De acordo com o banco de dados escolhido, a ferramenta prepara comandos específicos para que o experimento possa ser aplicado ao banco de dados em questão. Por exemplo, os bancos PostegreSQL e MongoDB utilizam métodos distintos fazer a inserção em lote. No PostegreSQL a ferramenta utiliza a funcionalidade denominada *Prepared Statements*, que permite fazer várias operações simultâneas sem variações sintáticas, já para o MongoDB a ferramenta constrói um JSON para inserção que é formado por uma lista de objetos da classe *Document*. Através dos parâmetros de entrada, a ferramenta faz a distinção de quais métodos utilizar apenas identificando o banco no qual se deseja fazer o experimento.

5.3 Resultados

As amostras de tempo de execução das inserções foram sumarizadas na forma de médias e intervalos de confiança (considerando 95% de confiança) para cada fator e seus respectivos níveis. Essas estatísticas são apresentadas na forma de gráficos nesta seção.

5.3.1 Inserção

A Figura 2a mostra o gráfico de inserção em lote. Esse gráfico demonstra a média do tempo das amostras variando de acordo com a quantidade de estações concorrentes. Pode-se observar que o MongoDB obteve um desempenho maior em relação aos demais bancos de dados, atingindo 86,83 ms no caso com 8 estações concorrentes, um tempo que é menor do que o obtido pelos bancos PostgreSQL e VoltDB, inclusive quando se considera o caso básico com apenas duas estações concorrentes, em que obtiveram, respectivamente, 129,20 ms e 1099,0 ms. O Voltdb se destaca por obter tempos de inserção médios elevados (aproximadamente 1 s com 2 estações concorrentes e 4 s com 8 estações concorrentes) comparado aos outros bancos de dados avaliados. Pode-se concluir, deste resultado, que o Voltdb, com as configurações padrão, não é um banco de dados adequado a cenários em que são feitas inserções em lote.

No experimento com inserções em tempo real (Figura 2b) observa-se que o MongoDB obteve novamente o menor tempo, com um aumento do tempo médio de inserção apenas a partir de 5 estações concorrentes. O PostgreSQL, apesar de apresentar um tempo médio maior, mantêm-se mais estável com o crescimento do número de estações concorrentes, de modo que ao se projetar cenários com mais estações concorrentes (por meio de regressão linear), mantendo-se as taxas de crescimento de ambos os bancos, o MongoDB obteria um tempo maior que o do PostgreSQL ao atingir 13 estações concorrentes. Enquanto o VoltDB teve um tempo de inserção mais baixo que o PostgreSQL para até 4 estações concorrentes, a taxa de crescimento do tempo de inserção do VoltDB é a mais elevada, de modo que a partir de 5 estações concorrentes o tempo de inserção excedeu todos os demais bancos.

5.3.2 Consultas

Nos experimentos de consultas em lote por estação (Figura 3a) pode-se observar que o Mongodb obteve baixa variação do tempo de inserção com o aumento do número de consultas concorrentes, e médias mais

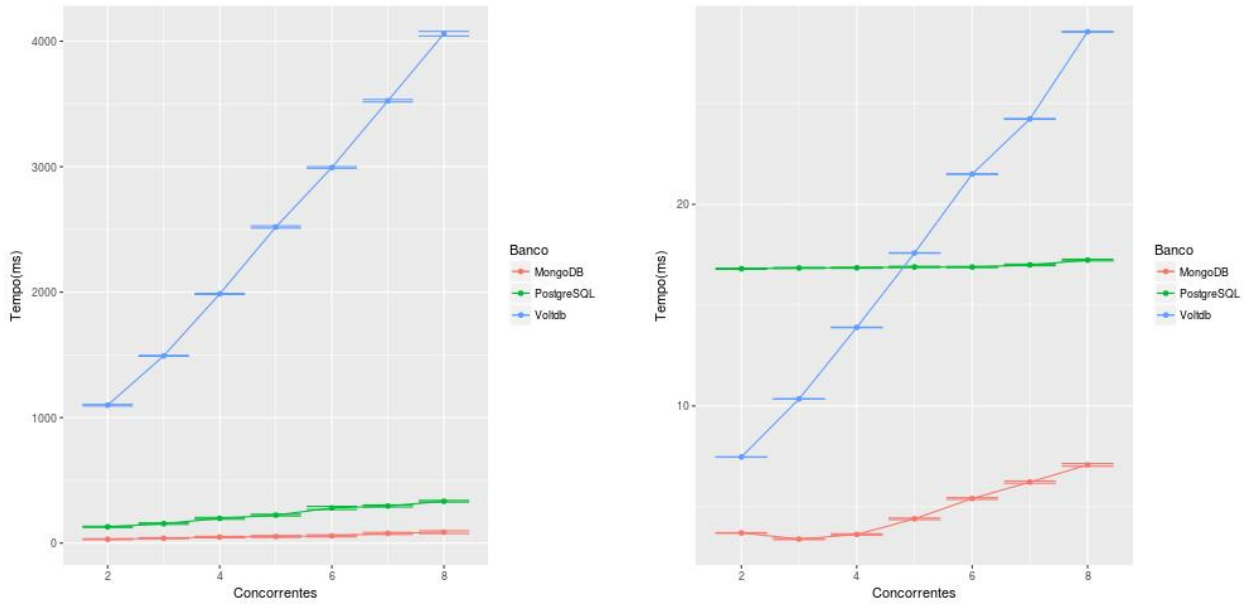

(a) Por Dia

(b) Por Tempo Real

Figura 2: Tempos médios de inserção e seus respectivos intervalos de confiança, para cada banco em cada cenário.

baixas quando comparadas aos demais bancos. Por outro lado, o tempo médio de leitura em lote do PostgreSQL e do VoltDB, para os casos testados, cresce de forma linear com o número de consultas concorrentes, sendo que as médias de tempo de leitura do VoltDB são as mais altas dentre os bancos avaliados.

Os resultados para o experimento de consulta em lote por sensor foram semelhantes à consulta em lote de estações. Contudo, o tempo médio de todos os bancos foi ligeiramente maior neste caso. Isso se dá pela forma como os dados estão inseridos no banco. No momento da inserção, cada estação insere os dados referentes a todos os seus 7 sensores, coletados a cada 10 minutos. Deste modo, os dados dos 7 sensores são armazenados sequencialmente na tabela `Historico`. Tal forma de organização dos dados impacta positivamente o tempo de consulta por estação e, concomitantemente, impacta negativamente o tempo de consulta por sensor, pois obriga a seleção de registros não-contíguos na tabela `Historico`.

Os resultados do experimento de consulta em tempo real por estação são mostrados na Figura 4a. Neste caso, o desempenho do MongoDB mantém-se próximo do obtido no experimento de consulta em lote, permanecendo com o os tempos médios mais baixos. A mudança ocorre entre o PostgreSQL e o Voltdb, já que este obteve um tempo médio de inserção mais baixo que o PostgreSQL. Na Figura 4b pode-se observar que os resultados para a consulta em tempo real por sensor são semelhantes aos obtidos no experimento de consulta em tempo real por estação. Isto ocorre porque, diferentemente do caso de consultas em lote, as consultas em tempo real capturam apenas um pequeno conjunto de dados, não impondo cargas diferentes ao banco.

6 Cronograma de Execução

As ações desempenhadas durante o período desta pesquisa são apresentadas na Tabela 6, visando apresentar o que foi cumprido até o momento.

A orientação e escrita de relatórios, relativa à atividade A.1 foi executada durante todo o período do plano de trabalho. As atividades A.2 e A.3 foram finalizadas na primeira etapa do projeto. Na etapa final foi finalizada a atividade A.4, em que foi desenvolvida uma ferramenta para execução dos experimentos de inserção e consulta de dados reais.

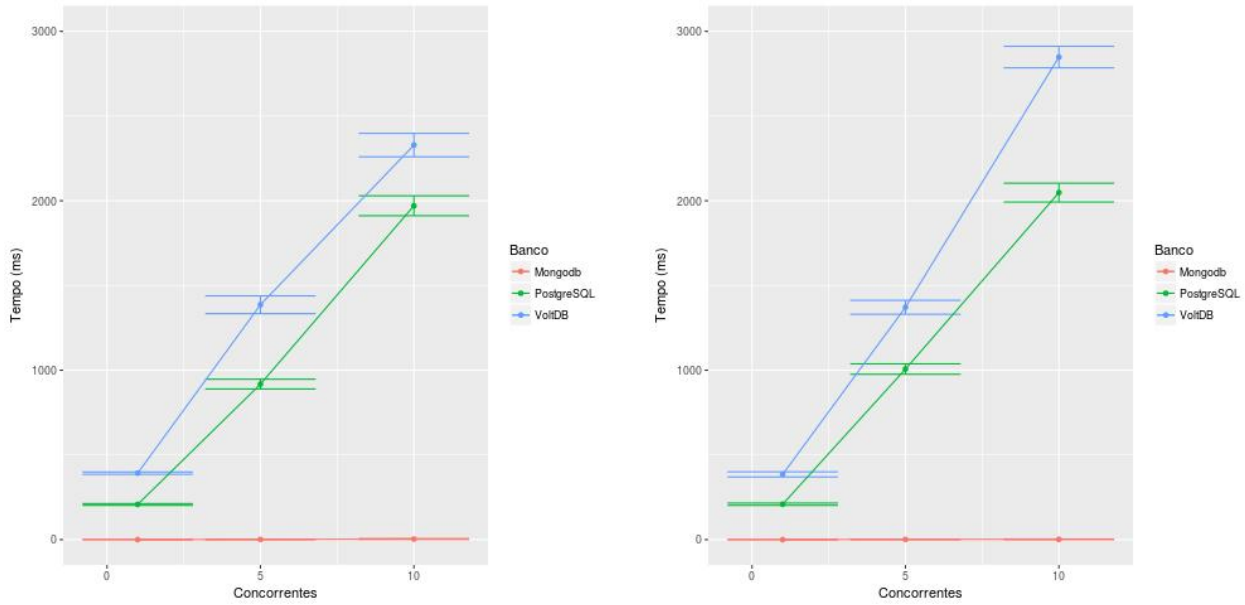

(a) Por Estação (b) Por Sensor

Figura 3: Tempos médios de leitura em lote e seus respectivos intervalos de confiança, para cada banco em cada cenário.

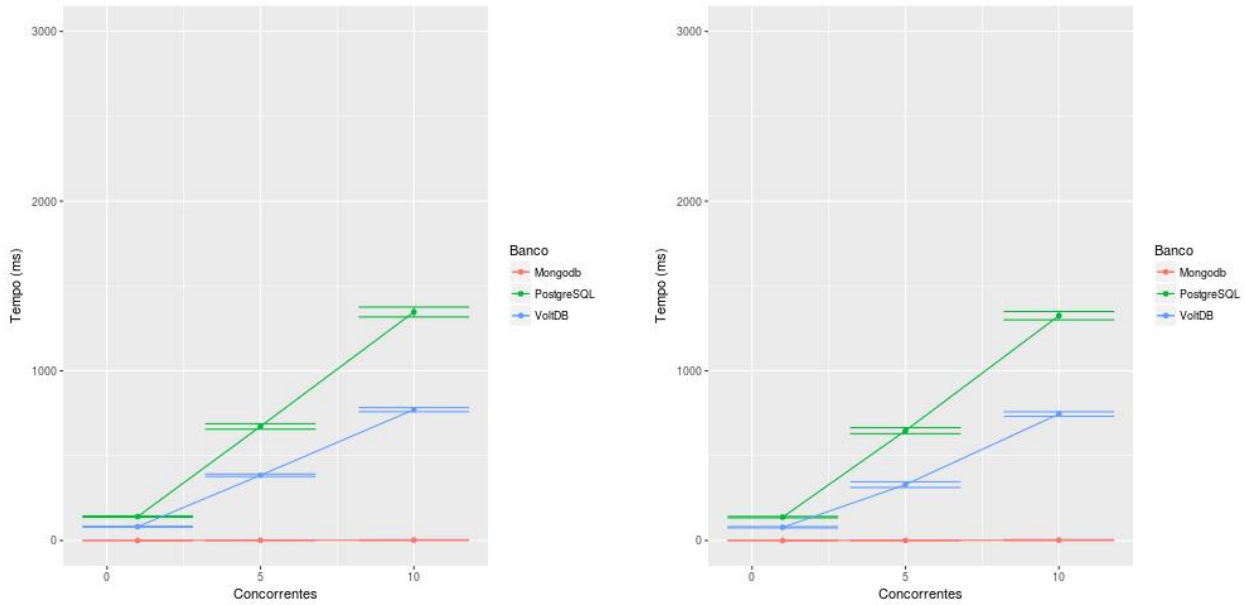

(a) Por Estação (b) Por Sensor

Figura 4: Tempos médios de leitura em tempo real e seus respectivos intervalos de confiança, para cada banco em cada cenário.

Na atividade A.5 toda estrutura do ambiente foi preparada de acordo com outras encontradas na literatura e com os recursos disponíveis para o projeto. Além disso, nesta atividade foram definidos os parâmetros, fatores e métricas do experimento, conforme relatado na Seção 5.2. As execuções dos experimentos (atividade A.6) foram feitas em máquinas virtuais instaladas nos servidores do Laboratório de Realidades Complexas pertecente ao CENAPESQ/UFRPE.

Atividade	Situação em 07/2017
A.1: Orientação e escrita de relatório	Finalizado
A.2: Levantamento do estado da arte	Finalizado
A.3: Análise dos requisitos	Finalizado
A.4: Desenvolvimento de ferramentas de emulação	Finalizado
A.5: Preparação do ambiente de testes	Finalizado
A.6: Avaliação de desempenho	Finalizado

Tabela 6: Status das atividades do plano de trabalho

7 Considerações Finais

Com a análise dos resultados dos experimentos podemos observar que o MongoDB obteve o menor tempo de execução para todas as tarefas testadas. Um cenário em que esta observação pode não proceder é o caso das inserções em tempo real, já que, mantidas as taxas de crescimento, a projeção das retas mostra que o PostgreSQL sobrepujaria o MongoDB. Esses resultados corroboram em parte os resultados de Phan et al. [8]. Seus experimentos mostram que o MongoDB oferece o melhor desempenho nas operações de escrita e um desempenho de leitura pouco pior do que os outros bancos testados. Contudo, deve-se ressaltar que as comparações não incluíram os bancos PostgreSQL e Voltdb. Também em [9] o Mongodb é apontado como um boa escolha por apresentar, em seus experimentos, o melhor desempenho em ambas as operações.

O PostgreSQL apresentou o segundo menor tempo de execução de inserções e consultas em lote, enquanto que o VoltDB apresentou tempo mais baixo apenas para consultas em tempo real. Este resultado é importante, porque procura preencher uma lacuna existente na literatura sobre o desempenho comparativo de bancos de dados NewSQL no cenário de dados de sensores, pois conforme explicitado na Seção 5.1, esta classe de bancos figuravam apenas em avaliações qualitativas até o momento.

Observou-se ainda com estes experimentos que o tipo da consulta e a forma como os dados são armazenados no banco tem impacto direto sobre os tempos de execução das operações. Apesar de ser aparentemente intuitivo, este resultado confirma a crítica de que o uso de bases de dados sintéticas e organizações de dados simplórias, como aquelas observadas em trabalhos anteriores (cf. Seção 5.1), faz com que os resultados apresentados nesses trabalhos se distanciem da realidade, já que é comum que sistemas de sensoriamento envolvam a criação de modelos de dados mais elaborados e a realização de consultas mais complexas.

Um outro resultado importante é que, de forma geral, os tempos de execução das operações nestes bancos tendem a crescer linearmente com o nível de concorrência no ambiente. Desta forma, assumindo-se mantidas as propriedades observadas nos gráficos, pode-se facilmente prever o comportamento destes bancos em cenários com maiores níveis de concorrência. Contudo, para maior segurança deste resultado e de suas projeções seria necessário experimentar com um maior número de estações/consultas concorrentes.

A ferramenta de execução parametrizada pode ser destacada como uma contribuição desta iniciação científica. Por meio dela, foi possível automatizar as execuções das atividades e, por meio de pequenas modificações dos parâmetros de entrada, efetuar os diferentes experimentos propostos neste plano. Desta forma, a ferramenta se mostra uma candidata para ser utilizada em experimentos futuros, dentro do projeto de pesquisa.

Como próximos passos, deseja-se consolidar os resultados obtidos na forma de um artigo científico a ser submetido para conferências na área de computação em nuvem e internet das coisas.

8 Referências Bibliográficas

[1] M. Benghanem, “Measurement of meteorological data based on wireless data acquisition system monitoring,” *Applied energy*, vol. 86, no. 12, pp. 2651–2660, 2009.

[2] R. Morais, M. A. Fernandes, S. G. Matos, C. Serôdio, P. Ferreira, and M. Reis, “A zigbee multi-powered wireless acquisition device for remote sensing applications in precision viticulture,” *Computers and electronics in agriculture*, vol. 62, no. 2, pp. 94–106, 2008.

[3] C. Perera, A. Zaslavsky, P. Christen, and D. Georgakopoulos, “Sensing as a service model for smart cities supported by internet of things,” *Transactions on Emerging Telecommunications Technologies*, vol. 25, no. 1, pp. 81–93, 2014.

[4] A. Zaslavsky, C. Perera, and D. Georgakopoulos, “Sensing as a service and big data,” *arXiv preprint arXiv:1301.0159*, 2013.

[5] E. Brewer, “Cap twelve years later: How the”rules”have changed,” *Computer*, vol. 45, no. 2, pp. 23–29, 2012.

[6] J. S. Van der Veen, B. Van der Waaij, and R. J. Meijer, “Sensor data storage performance: Sql or nosql, physical or virtual,” in *Cloud Computing (CLOUD), 2012 IEEE 5th International Conference on*. IEEE, 2012, pp. 431–438.

[7] K. Grolinger, W. A. Higashino, A. Tiwari, and M. A. Capretz, “Data management in cloud environments: Nosql and newsql data stores,” *Journal of Cloud Computing: Advances, Systems and Applications*, vol. 2, no. 1, p. 22, 2013.

[8] T. A. M. Phan, J. K. Nurminen, and M. Di Francesco, “Cloud databases for internet-of-things data,” in *Internet of Things (iThings), 2014 IEEE International Conference on, and Green Computing and Communications (GreenCom), IEEE and Cyber, Physical and Social Computing (CPSCom), IEEE*. IEEE, 2014, pp. 117–124.

[9] Y. Li and S. Manoharan, “A performance comparison of sql and nosql databases,” in *Communications, Computers and Signal Processing (PACRIM), 2013 IEEE Pacific Rim Conference on*. IEEE, 2013, pp. 15–19.

[10] H. Fatima and K. WASNIK, “COMPARISON OF SQL, NOSQL AND NEW SQL DATABASES IN LIGHT OF INTERNET OF THINGS – A SURVEY,” in *Proceedings of 48th IRF International Conference*, Pune, India, Jan. 2016.

9 Atividades Relevantes Desenvolvidas pelo Aluno

Durante a vigência do plano, o aluno desenvolveu atividade correlatas em disciplinas do curso. Deve-se destacar a disciplina de Projeto de Banco de Dados, em que o aluno trabalhou com a modelagem e implementação de um banco de dados populado com dados do censo educacional de ensino superior de 2014, com o intuito de gerar informações sobre desempenho da educação superior.

O aluno teve ainda a oportunidade de aprender e pôr em prática muitas tecnologias e ferramentas empregadas na execução dos experimentos. Pode-se destacar o aprendizado da operação de diferentes bancos de dados utilizados nos experimentos (PostgreSQL, MongoDB e VoltDB), bem como de suas bibliotecas de programação em Java. Pode-se ainda destacar o aprofundamento do conhecimento de sistemas Linux e linguagem de programação ShellScript como facilitador para automação dos experimentos.

O aluno pôde também aplicar os conhecimentos teóricos obtidos em seu curso em sua pesquisa ao manipular dados reais e empregar ferramental estatístico apropriado (intervalos de confiança, regressão etc), por meio de ferramentas de análise de dados como o R.

Destaca-se por fim como uma atividade e contribuição relevante do aluno, a sua participação na equipe de organização e gerência do cluster de servidores disponíveis no Laboratório de Realidades Complexas do CENAPESQ/UFRPE. Sua contribuição foi importante para a UFRPE como um todo por tornar operacional um dos serviços deste laboratório multi-usuário da UFRPE que se encontrava inativo.

10 Dificuldades Encontradas

Uma das principais dificuldades encontradas no desenvolvimento deste plano de trabalho ocorreu na atividade do levantamento do estado da arte. Como a literatura na área de avaliação de desempenho de bancos de dados é bastante vasta, o aluno precisou de tempo para selecionar somente os artigos estritamente correlacionados ao problema de pesquisa de seu plano. A partir destes foi possível encontrar as lacunas existentes na literatura de modo a elaborar experimentos pontuais que trouxessem novos dados para a área.

Um outro problema encontrado foi a aquisição de dados reais, tomada como um dos diferenciais deste trabalho em relação aos existentes, que usam apenas dados sintéticos. A principal dificuldade foi obter bases de dados estruturadas e com dados suficientes para execução do experimento. Bases com longo histórico, geralmente não estão disponíveis ao público em geral de uma forma estruturada, mas sim através de ferramentas de visualização que dificultam a aquisição dos dados em lote para experimentação. Contudo, após consulta a profissionais especialistas no uso destes dados, foi possível localizar bases de dados abertos com um histórico razoável e estrutura bem definida.

11 Parecer do Orientador

Airton Martins Neris, desempenhou as atividades de seu plano de trabalho de maneira dedicada. Durante o tempo de execução do plano, o aluno estudou a literatura recente da área, focando em trabalhos correlatos. Sua dedicação se expressa claramente ao tentar sobrepujar deficiências iniciais de sua formação como a leitura de textos em inglês, dificuldade em compreender métodos e metodologias e escrita de relatórios. Neste sentido, o aluno evoluiu bastante ao longo da execução do plano, e se destacou pela análise aprofundada e estruturada dos artigos lidos e pela execução criteriosa dos experimentos planejados.

O aluno tem participado ativamente das atividades no laboratório JuáLabs[2] e colaborado na apresentação de seminários internos e discussões acerca deste e de outros projetos desenvolvidos no laboratório.

Segundo relato do próprio aluno, a participação neste projeto de pesquisa serviu para fazê-lo conhecer os fundamentos do método científico e o dia-a-dia da ciência. Também permitiu que conhecesse novas tecnologias e métodos que lhe serão úteis em sua carreira. A execução das atividades do plano tem afetado positivamente a sua compreensão das disciplinas do curso. Como exemplo pode-se citar a disciplina de Projeto de Banco de Dados.

Em minha avaliação, o aluno evoluiu bastante ao longo da orientação e desenvolveu com bom aproveitamento as atividades que para ele foram planejadas dentro do projeto.

[2] https://jualabs.wordpress.com/

Recife, 12 de novembro de 2019

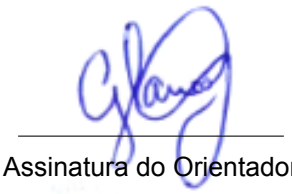

Assinatura do Orientador

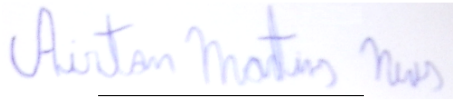

Assinatura do Aluno